Expressão Diferencial de Genes com dados de RNA-Seq: O que eu devo saber?

Dia 1

Juliana Costa Silva[1 2 3] |

Universidade Tecnológica Federal do Paraná - Campus Cornélio Procópio

Roteiro

1. Apresentação
2. O curso
   - Conteúdo
   - Programação
3. Introdução
4. Dados de expressão, como registrar expressão de genes?
5. Análises com dados de RNA-Seq (expressão)
   - Mapeamento
   - Contagem
6. Expressão
7. Referências

Quem sou eu?

Juliana Costa Silva

- **Graduada em Tecnologia em Análise e Desenvolvimento de Sistemas** pela UTFPR – Universidade Tecnológica Federal do Paraná (Cornélio Procópio) - 2011 a 2014;
- **Mestre em Bioinformática** pela UTFPR – Universidade Tecnológica Federal do Paraná (Cornélio Procópio) - 2015 a 2017;
- **Doutora em Ciência da Computação** pela UFPR - Universidade Federal do Paraná (Curitiba) - 2020 a 2025.

Por favor, apresente-se.

- Seu nome?
- Sua instituição de ensino?
- Sua formação?
- Por que escolheu este mini-curso?



Conteúdo

- Conceito de expressão diferencial de genes;
- Como são gerados os dados de expressão;
- Métodos para identificar genes diferencialmente expressos;
- Análise de expressão com linguagem R;

Dia 1

Programação

1. O que é expressão de genes?
2. Dados de expressão, como registrar expressão de genes?
3. RNA-Seq: dados e etapas de análise;
4. Tipos de experimentos e perguntas.

Dia 2

Programação

Principais passos para análise de expressão.

O que vou precisar?

- Computador com R e RStudio instalados;
- Instalação dos pacotes edgeR, DESEq2 e suas dependências;

1. Dados de contagem, como importar?
2. Métodos de análise de expressão: paramétricos e não paramétricos;

Dia 2

Programação

Prática em análise de expressão.

O que vou precisar?

- Computador com R e RStudio instalados;
- Instalação dos pacotes edgeR, DESEq2 e suas dependências;
- Conjunto de dados;

1. Meus dados de contagem, como importar?
2. Métodos de análise de expressão: como inetrpretar os resultados?;
3. Prática e perguntas.

Introdução

1. O que é expressão de genes?
2. Dados de expressão, como registrar expressão de genes?
3. RNA-Seq: dados e etapas de análise;
4. Tipos de experimentos e perguntas.

Expressão de genes

Expressão de um gene pode ser definida como:

- criação de um mRNA maduro;
- Em geral é seguido pela expressão da proteína correspondente;
- criação de uma proteína funcional;
- no processo de síntese proteica já visto.

Célula - Expressão genica

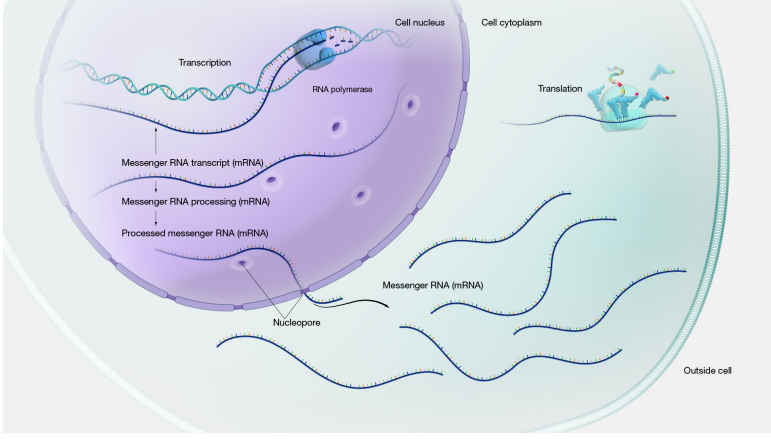


Figure: Esquema de expressão gênica. **Fonte:** Brody 2026.

Dogma Central da Biologia Molecular

O DNA através do processo de transcrição faz o RNA, que na maior parte das vezes, gera apenas uma proteína através do processo de tradução.

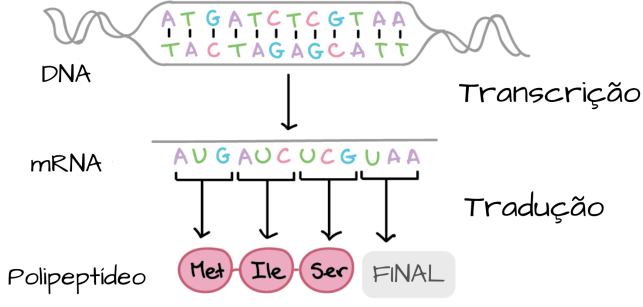


Figure: Dogma Central da Genética. **Fonte:** Adaptado de Ponomarenko et al. 2021

Ativação e repressão

- Um gene pode ser **ativado** (induzido):
  - ele não estava sendo expresso e **passa a ser** expresso.
- Ou **reprimido**:
  - Ele estava sendo expresso e **deixa de ser** expresso;
  - Ou não estava sendo expresso e continua sem ser expresso.

Sobre expressão...

Como regra geral, todas as células somáticas (não reprodutivas) de um organismo possuem exatamente o mesmo DNA[1].

Fatos

- Diferentes tecidos ou órgãos do corpo expressam diferentes genes;
- **Ex:** coração, cérebro, pele, pâncreas, pulmão, etc

Fatos [2]

- Um mesmo tecido ou órgão do corpo pode expressar/reprimir diferentes genes em diferentes situações:
- Ex: quando o nível de açúcar no sangue sobe, o pâncreas expressa insulina.

[1] Existem pequenas exceções e variações.

Por que estudar expressão de genes?

Para compreender os mecanismos que geram algumas caraterísticas fenotípicas, é necessário compreender o complexo mecanismo de regulação gênica.



Perguntas Essenciais

- O que causa a ativação ou repressão de um gene?
- Quanto de um gene é expresso numa dada condição?

Avaliando a Expressão

De modo geral análises de expressão buscam identificar como a atividade transcricional de um gene interfere no fenótipo de um organismo.

Técnicas populares para identificar expressão

1. qRT-PCR;
2. MicroArray;
3. RNA-Seq;
4. Single-Cell RNA-Seq;

qRT-PCR

qRT-PCR: reação em cadeia da polimerase da transcrição reversa em tempo real (do inglês *real-time reverse transcription polymerase chain reaction*) Ladeira, Isaac, and Ferreira 2011.

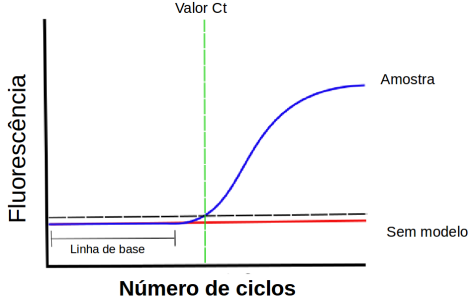


Figure: Nível de limiar em uma curva de amplificação qRT-PCR. A linha vermelha indica o nível de fluorescência do controle utilizado (*Sem modelo*), a linha azul indica a curva de amplificação da sequência de interesse (*Amostra*), a linha tracejada em verde é o limiar dos ciclos da PCR (C_t).Fonte: Adaptado de Bustin et al. 2009

Transcritoma

Conjunto de todas as moléculas de RNA (transcritos) em uma célula, tecido ou organismo em uma dada condição fisiológica ou patológica.

Como se obtém um transcritoma?

- Por sequenciamento (**RNA-seq**);
- Num experimento, extrai-se todo o RNA do pool de células;
- Faz-se um enriquecimento para RNAs que não sejam ribossomais – os RNA ribossomais não participam do processo de expressão;
- Estamos interessados nos mRNA, ncRNA (non coding) e outros tipos de RNA não ribossomais;
- Usa-se transcrição reversa para gerar cDNA;
- O cDNA é sequenciado.

Análises computacionais

Os dados precisam ser processados computacionalmente:

- Máquinas sequenciadoras nos fornecem em geral milhões de reads:
- um read é um fragmento de cDNA;
- o tamanho do read depende da tecnologia de sequenciamento;
- no caso de Illumina, costumam ter entre 150 e 400 bp (*base pair*);
- obtidos os reads, estes devem ser mapeados no genoma.

O que é RNA-Seq?

- Este nome foi dado a tecnologias de sequenciamento chamadas de "nova geração" (*Next-generation sequencing*) aplicadas aos transcriptomas, ou seja, às regiões do DNA transcritas

Utilidades

- Analisar expressão diferencial de diferentes condições ambientais ou tecidos;
- Analisar diferentes isoformas (*splicing* alternativo);
- Identificar regiões de transcrição em um genoma;
- Identificar moléculas de RNA que participam de processos regulatórios;
- Entre outros...

Análises RNA-Seq

Descreveremos um experimento típico de análise de expressão diferencial de genes. Considere o seguinte cenário:

- Dados de RNA-Seq;
- Organismo investigado possui genoma sequenciado;
- Organismo investigado possui genoma anotado;

Os passos das análises de expressão dependem do objetivo do estudo, organismo investigado, disponibilidade de dados e amostras, entre outros. Desse modo, para outros cenários esses passos podem ser diferentes.

Análises RNA-Seq - sequenciamento

Queremos avaliar a variação de expressão entre duas condições, controle e tratado (com alguma perturbação específica).
São sequenciadas amostras nas condições descritas.
Os *reads* resultantes do sequenciamento são alinhados com o genoma de referência ou transcriptoma.

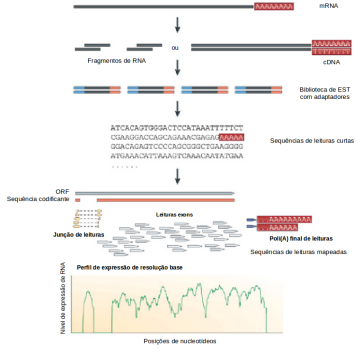


Figure: Exemplo de um experimento tipico de RNA-Seq. **Fonte:** Adaptado de Wang, Gerstein, and Snyder 2009

Análises RNA-Seq - o experimento

Os *reads* podem ser gerados de duas formas *single-end* e *paired-end*.

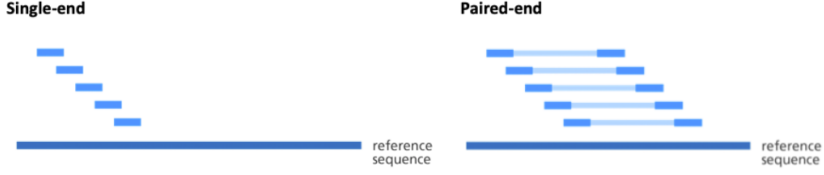


Figure: Exemplo de *reads* gerados em um experimento típico de RNA-Seq, com bibliotecas *single-end* e *paired-end*. **Fonte:** Sanches 2022.

Análise computacional (RNA-Seq)

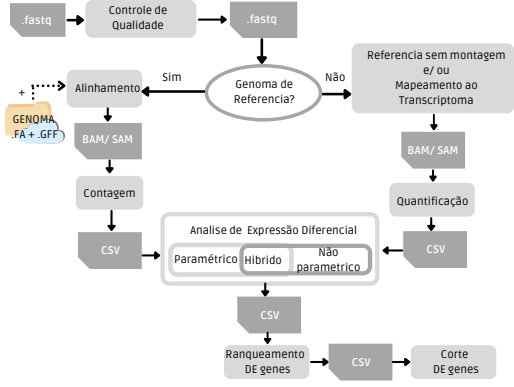


Figure: Esquema com os principais passos da analise de expressão em massa com dados de RNA-Seq. **Fonte:** Costa-Silva et al. 2023

Arquivos FASTA

Arquivos FASTA são utilizados como saída de sequenciadores e também é o formato em que comumente são disponibilizados genomas e transcriptomas.

```
>Sequence_1 assembly1
CCCTAAACCCTAAACCCTAAACCCTAAACCTCTGAATCCTTAATCCCTAAATCCCTAAAT
CTTTAAATCCTACATCCATGAATCCCTAAATACCTAATTCCCTAAACCCGAAACCGGTTT
CTCTGGTTGAAAATCATTGTGTATATAATGATAATTTTATCGTTTTTATGTAATTGCTTA
TTGTTGTGTGTAGATTTTTTAAAAATATCATTTGAGGTCAATACAAATCCTATTTCTTGT
GGTTTTCTTTCCTTCACTTAGCTATGGATGGTTTATCTTCATTTGTTATATTGGATACAA
GCTTTGCTACGATCTACATTTGGGAATGTGAGTCTCTTATTGTAACCTTAGGGTTGGTTT
ATCTCAAGAATCTTATTAATTGTTTGGACTGTTTATGTTTGGACATTTATTGTCATTCTT
>Sequence_2
CCCTAAACCCTAAACCCTAAACCCTAAACCTCTGAATCCTTAATCCCTAAATCCCTAAAT
CTTTAAATCCTACATCCATGAATCCCTAAATACCTAATTCCCTAAACCCGAAACCGGTTT
CTCTGGTTGAAAATCATTGTGTATATAATGATAATTTTATCGTTTTTATGTAATTGCTTA
TTGTTGTGTGTAGATTTTTTAAAAATATCATTTGAGGTCAATACAAATCCTATTTCTTGT
GGTTTTCTTTCCTTCACTTAGCTATGGATGGTTTATCTTCATTTGTTATATTGGATACAA
GCTTTGCTACGATCTACATTTGGGAATGTGAGTCTCTTATTGTAACCTTAGGGTTGGTTT
ATCTCAAGAATCTTATTAATTGTTTGGACTGTTTATGTTTGGACATTTATTGTCATTCTT
```

Figure: Exemplo de duas sequências em um arquivo FASTA: Cada sequência é representado por um marcador de início da sequência $>$ + ID da sequência, na linha abaixo ao ID a sequência.

Arquivos FASTQ

Sequenciadores podem gerar dados em diversos formatos, o formato FASTQ informa a sequência e a qualidade de cada par de base sequenciado, o valor de qualidade pode ser utilizado para "limpeza", onde excluímos os *reads* de baixa qualidade.
Formato FASTQ.

```
@SRR001666.1 071112_SLXA-EAS1_s_7:5:1:817:345 length=36
GGGTGATGGCCGCTGCCGATGGCGTCAAATCCCACC
+SRR001666.1 071112_SLXA-EAS1_s_7:5:1:817:345 length=36
IIIIIIIIIIIIIIIIIIIIIIIIIIIII9IG9IC
```

Figure: Read em um arquivo FASTQ: Cada read é representado por 4 linhas: ID, sequência, ID, Qualidade da sequência.

Mapeamento

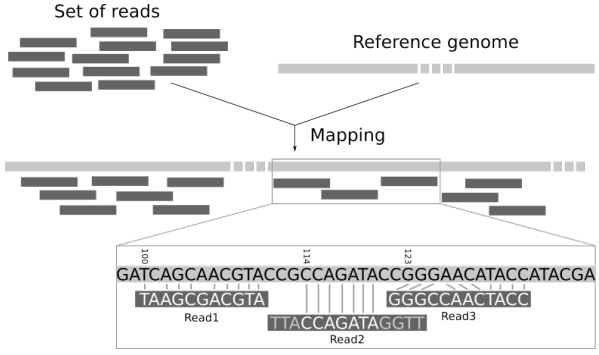


Figure: Esquema de processo de mapeamento. O mapeamento tem como objetivo recuperar a região do genoma, ou transcrito que originou cada um dos reads gerados pelo sequenciador. **Fonte:** Hiltemann et al. 2023.

Mapeamento - paired-end

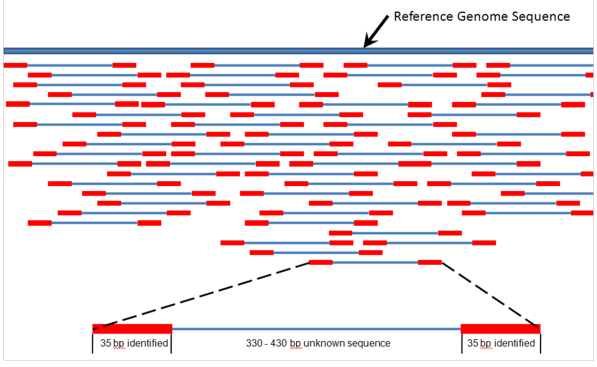


Figure: Esquema de processo de mapeamento de reads sequenciado em paired-end.

Fonte: wikipedia

Análises RNA-Seq - o experimento

Os *reads* são mapeados para identificar de qual região do genoma foram transcritos.

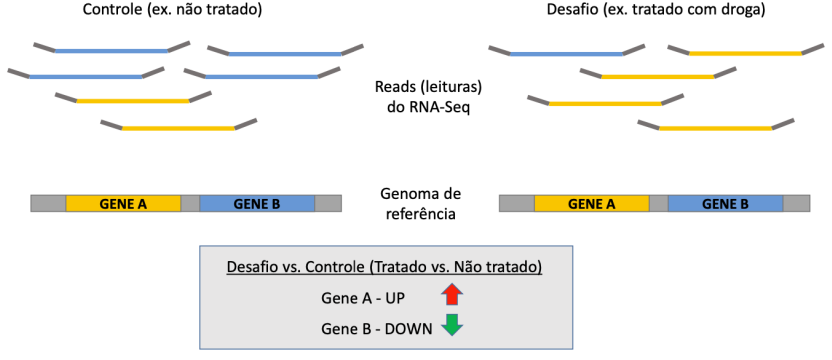


Figure: Exemplo de *reads* gerados em um experimento típico de RNA-Seq, onde o objetivo é comparar expressão de genes na situação controle e tratado. **Fonte:** Sanches 2022.

Análises RNA-Seq - contagem

Para mapeamentos de organismos com genoma anotado, é necessário fornecer o arquivo de anotação, formato GFF ou GTF.

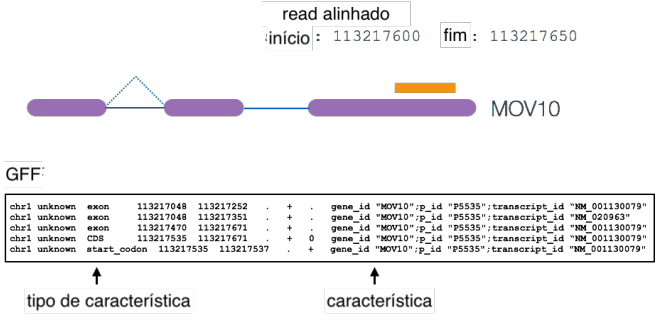


Figure: Esquema mostrando região indicada no mapeamento, em laranja o read posicionado na região onde foi mapeado em relação ao gene MOV10. Abaixo o arquivo de anotação que indica qual região do genoma representa qual gene.
Fonte: Adaptado dehbctraining 2018.

Análises RNA-Seq - tabela contagem

gene	UHR1	UHR2	UHR3	UHR4	Brain1	Brain2	Brain3	Brain4
ENSG00000242268.2	0	0	0	1	0	0	2	1
ENSG00000167578.12	22	37	16	39	110	93	76	65
ENSG00000270112.2	0	1	1	0	28	20	16	24
ENSG00000078237.4	24	20	23	21	8	7	11	9
ENSG00000269416.1	33	25	29	22	1	1	1	0
ENSG00000268332.1	7	6	8	5	22	16	25	12

Figure: Tabela de contagem.**Fonte:** hbctraining 2018.

Identificando a Expressão Diferencial

Para identificar genes diferencialmente expressos é necessário calcular a relevância da diferença de contagem. Se um gene é mais extenso em quantidade de pares de base, teremos mais reads mapeados na região dele, o que não implica necessariamente em uma expressão diferencial.



	Controle	Tratamento	FoldChange	log_2FC
Gene X	28	5	0,18	-2,49
Gene Y	5	28	5,60	2,49

Referências I

[1] Lawrence Brody. *Gene Expression*. 2026. URL: https://www.genome.gov/genetics-glossary/Gene-Expression.

[2] Stephen A. Bustin et al. “The MIQE guidelines: Minimum information for publication of quantitative real-time PCR experiments”. In: *Clinical Chemistry* 55.4 (Apr. 2009), pp. 611–622. ISSN: 00099147. DOI: 10.1373/CLINCHEM.2008.112797.

[3] Juliana Costa-Silva et al. “Temporal progress of gene expression analysis with RNA-Seq data: A review on the relationship between computational methods”. In: *Computational and Structural Biotechnology Journal* 21 (2023), pp. 86–98. ISSN: 20010370. DOI: 10.1016/j.csbj.2022.11.051.

[4] INC. DGLab. *Genótipo e Fenótipo: entenda o que são e como se relacionam*. 2021. URL: https://dglab.com.br/blog/genotipo-fenotipo/.

[5] hbctraining. *Introduction to RNA-Seq using high-performance computing - ARCHIVED*. 2018. URL: https://hbctraining.github.io/Intro-to-rnaseq-hpc-O2/lessons/05_counting_reads.html.

Referências II

[6] Saskia Hiltemann et al. “Galaxy Training: A powerful framework for teaching!” In: *PLoS Computational Biology* 19 (1 Jan. 2023). ISSN: 15537358. DOI: 10.1371/JOURNAL.PCBI.1010752.

[7] Pedro Ribeiro Soares de Ladeira, Cesar Isaac, and Marcus Castro Ferreira. “Reação em cadeia da polimerase da transcrição reversa em tempo real”. In: *Revista de Medicina* 90.1 (Mar. 2011), p. 47. ISSN: 1679-9836. DOI: 10.11606/issn.1679-9836.v90i1p47-51. URL: http://www.revistas.usp.br/revistadc/article/view/58883.

[8] Julia Ponomarenko et al. *Bioinformatics for Biologists*. 2021. URL: https://biocorecrg.github.io/CRG_Bioinformatics_for_Biologists_2021/.

[9] Pablo Rodrigo Sanches. *Conceitos Fundamentais sobre a metodologia para análise de RNA-Seq*. 2022.

[10] Zhong Wang, Mark Gerstein, and Michael Snyder. “RNA-Seq: a revolutionary tool for transcriptomics”. In: *Nature Reviews Genetics* 10.1 (Jan. 2009), pp. 57–63. ISSN: 1471-0056. DOI: 10.1038/nrg2484. URL: http://www.nature.com/articles/nrg2484.